Forzy — Monitoramento de Ativos Industriais

Challenge Sprint 4 · Documentação Final do Projeto

Disciplina: Front End & Mobile Development · **Professor:** Lucas Tadeu Cunha Rios **Repositório:** https://github.com/guilhermegamabs/py-challenge-sprint-4-front-end

Integrante	RM
Guilherme Gama	RM565293
Bruno Fernandes Nascimento	RM552574
Edgar Lódula de Assis	RM565260
Júlia Aben-Athar	RM566325
Igor Thiago Nakajima Vieira	RM563632

1. Introdução

A Forzy precisa que o operador de manutenção saiba **qual motor está degradando, por que, e o que fazer** — antes da parada. Nas Sprints 1 a 3 o grupo construiu, em Streamlit, a interface que responde a isso:

Sprint	Entrega
1	Cadastro técnico do ativo, consulta com filtros, dados brutos com conversão ADC → unidades de engenharia
2	SQLite, navegação Planta → Área → Ativo, dashboard com gauges e série temporal, OCR da placa via Gemini
3	Painel de Alertas e Estados como página inicial, 3 detectores de anomalia, resumos em linguagem natural, apoio à decisão, atualização automática

A Sprint 4 não traz funcionalidade nova. Este documento registra **o que mudou desde a entrega da Sprint 3**, os diferenciais e resultados da solução, o que ficou pendente e por quê, e uma proposta de evolução para arquitetura de produção.

O repositório da Sprint 4 foi criado **a partir do histórico da Sprint 3**: os commits anteriores estão preservados e cada mudança desta sprint é um commit isolado sobre `4df555c Sprint 3`. É por eles que a comparação pode ser conferida.

---

2. Evolução desde a Sprint 3

2.1 Ponto de partida — o que a Sprint 3 entregou

Commit `4df555c` (15/08/2026). Sete telas, organizadas em três grupos na sidebar:

Tela	Estado na Sprint 3
Painel de Alertas e Estados	KPIs da frota, resumo executivo por IA, cards de alerta, 3 recomendações priorizadas, histórico filtrável, timer de 5 s a 1 min
Navegação por Planta	Cards por área com status colorido e mini-leituras
Dashboard do Ativo	4 gauges com faixas warn/crit, série temporal com bandas, alertas do período
Consulta / Novo Equipamento / Módulo Técnico / Dados Brutos	CRUD com OCR da placa e conversão ADC

Camada analítica: resíduo de previsão, CUSUM e variância de janela (`app/services/analitico.py`); resumos pelo Gemini 2.5 Flash com fallback por template (`resumos.py`); ingestão do motor real `MOTOR-220V-01` a partir do Parquet da camada Silver.

Dívidas que a entrega carregava, levantadas na revisão de código no início desta sprint:

#	Problema	Onde
D1	Texto vindo do OCR, do cadastro e da LLM era interpolado cru em HTML renderizado com `unsafe_allow_html=True`	`cards_alerta.py`, `estilos.py`
D2	Nenhum teste automatizado	—
D3	`requirements.txt` sem versões	raiz
D4	Arquivos `.pyc` versionados desde a Sprint 1, apontando para módulos que já não existem	`app/__pycache__/`
D5	Toda a lógica acessível só pela interface Streamlit — nenhum outro cliente consegue consumir	arquitetura

2.2 O que foi adicionado, alterado ou corrigido

Commit	Tipo	Mudança	Resolve
`1ce16aa`	qualidade	Remove `.pyc` do versionamento	D4
`82f92e6`	correção	Helper `esc()` e escape em todos os componentes que recebem texto externo	D1
`1c17b0b`	qualidade	Versões fixadas em `requirements.txt`	D3
`43695c3`	qualidade	22 testes automatizados (`pytest`)	D2
`aa64f08`	arquitetura	Protótipo de API REST em FastAPI sobre a mesma camada de serviços	D5 (seção 5)
`b111b0a`	interface	Rótulo da sidebar atualizado para a Sprint 4	—
`e0727a6`	correção	Erros do próprio framework também saem no formato padrão em português	achado nesta sprint
`585134e`	correção	Mensagem legível quando o corpo da requisição não é JSON	achado nesta sprint

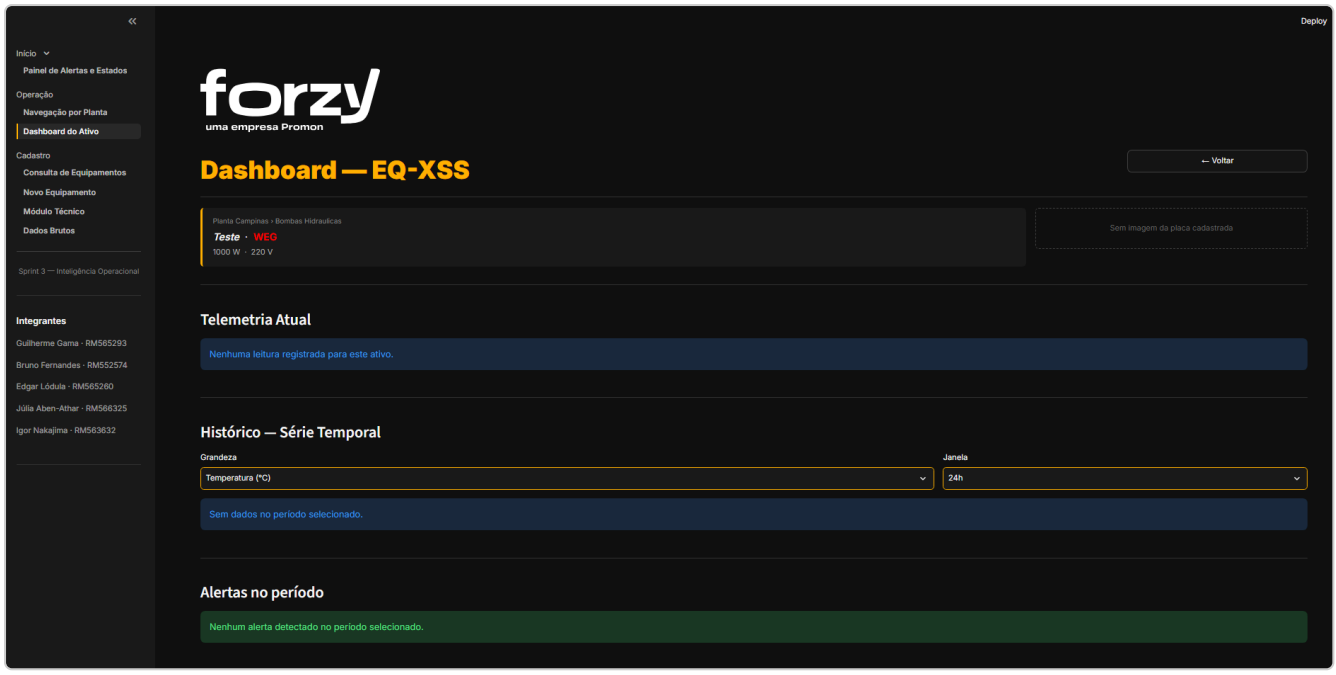
Total: **18 arquivos alterados, 611 linhas adicionadas, 25 removidas** (`git diff --stat 4df555c..HEAD`). Nenhuma tela foi removida nem teve comportamento alterado para o operador, além da correção de exibição do item D1.

2.3 Comparativos antes / depois

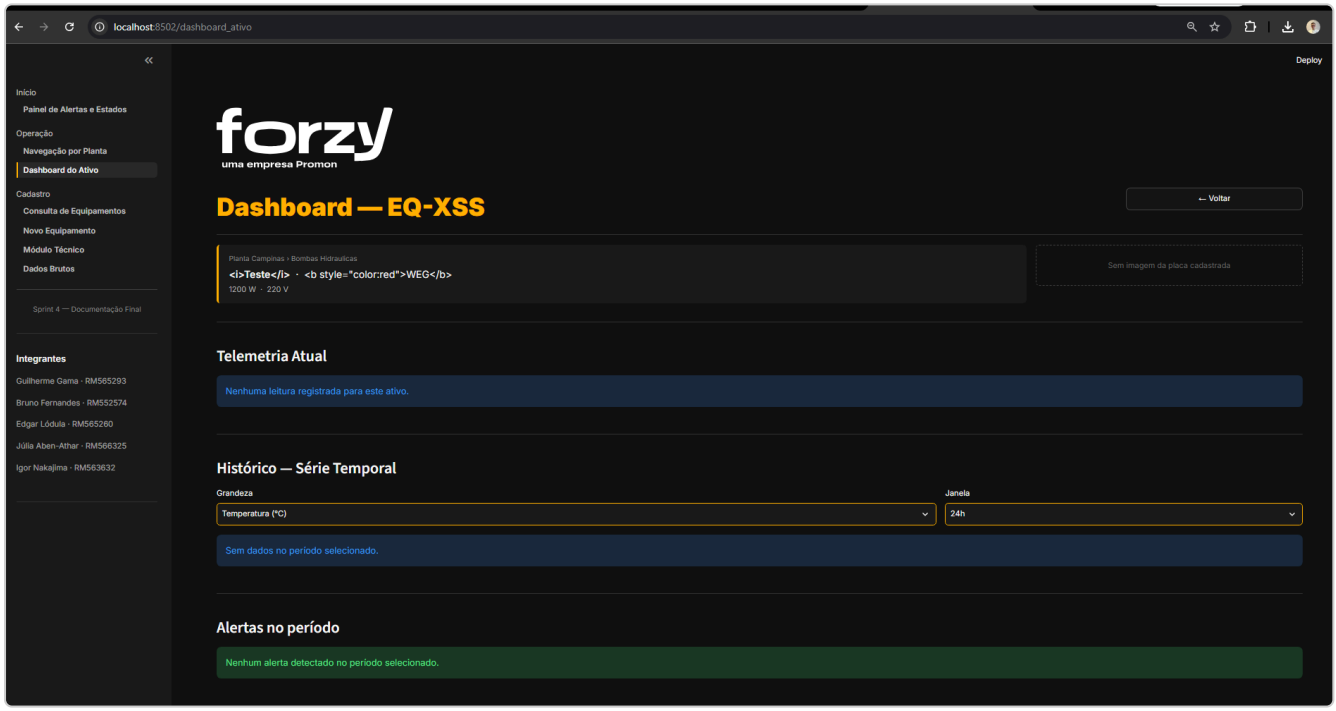
a) Texto externo virando HTML (D1)

Para provar o problema foi cadastrado o equipamento `EQ-XSS` com Modelo `<i>Teste</i>` e Fabricante `<b style="color:red">WEG</b>` — o tipo de texto que um OCR mal lido ou uma resposta inesperada da LLM pode produzir.

Antes — Sprint 3. O navegador interpreta o texto como marcação: "Teste" em itálico e "WEG" em vermelho. Um texto com `<img onerror=...>` executaria script.



Depois — Sprint 4. O mesmo registro aparece como texto literal.



A correção é um helper único, aplicado em todos os builders que recebem dado de fora:

```
# app/components/estilos.py
def esc(valor) -> str:
    """Escapa texto antes de interpolar em HTML renderizado com unsafe_allow_html.

    TAG, modelo e fabricante chegam do OCR e do cadastro manual; título e resumo
    chegam da LLM. Um `<` em qualquer um deles quebrava o card ou injetava markup.
    """
    return "" if valor is None else html.escape(str(valor))
```

```
# app/components/cards_alerta.py — html_card_alerta()
-        f'<strong style="color:{CORES["primary"]}; font-size:1.05rem;">{tag}</strong>'
+        f'<strong style="color:{CORES["primary"]}; font-size:1.05rem;">{esc(tag)}</strong>'
-        f' margin-top:10px;">{titulo}</div>'
+        f' margin-top:10px;">{esc(titulo)}</div>'
-        f' margin-top:6px;">{resumo}</div>'
+        f' margin-top:6px;">{esc(resumo)}</div>'
```

Pontos cobertos: card de alerta (TAG, título, resumo, causa, unidade, local), card de recomendação, resumo executivo, card de equipamento da Navegação por Planta, cabeçalho do Dashboard e as linhas ✓/⚠ do OCR no cadastro.

b) Testes automatizados (D2)

	Sprint 3	Sprint 4
Testes	0	**22**, todos passando em ~2 s
Detectores	validados só visualmente na demo	cada modo de falha tem um teste que exige o detector certo

Os testes da camada analítica não dependem do banco: uma série sintética substitui `get_historico` e cada modo de falha da demonstração é injetado nela.

```
def test_deriva_termica_lenta_dispara_cusum(monkeypatch):
    df = _serie()
    inicio = int(N * 0.75)
    df.loc[inicio:, "temperatura"] += np.linspace(0, 4.0, N - inicio)
    diag = _avaliar(monkeypatch, df)
    assert diag.detectores["cusum"]
    assert diag.alarme


def test_sensor_congelado_dispara_variancia(monkeypatch):
    df = _serie()
    for g in BASE:
        df.loc[N - 30 :, g] = df.loc[N - 31, g]
    diag = _avaliar(monkeypatch, df)
    assert diag.detectores["variancia"]
    assert diag.pista == analitico.PISTA_INSTRUMENTACAO
```

Arquivo	O que garante
`tests/test_analitico.py` (10)	Operação normal não dispara; spike → resíduo; deriva → CUSUM; sensor congelado → variância; regras de severidade; CUSUM acumula viés e ignora ruído
`tests/test_componentes.py` (4)	Nenhum componente deixa `<img onerror=...>` virar markup
`tests/test_api.py` (8)	API Key, propagação do `trace_id`, erros em português, feedback de IA — rodando contra SQLite temporário

Saída de `pytest -v` na Sprint 4:

```
tests/test_analitico.py::test_operacao_normal_nao_dispara PASSED
tests/test_analitico.py::test_spike_de_vibracao_dispara_residuo PASSED
tests/test_analitico.py::test_deriva_termica_lenta_dispara_cusum PASSED
tests/test_analitico.py::test_sensor_congelado_dispara_variancia PASSED
tests/test_analitico.py::test_sem_historico_devolve_none PASSED
tests/test_analitico.py::test_severidade[...] PASSED           (4 casos)
tests/test_analitico.py::test_cusum_acumula_vies_e_ignora_ruido PASSED
tests/test_api.py::test_health_e_publico PASSED
tests/test_api.py::test_sem_chave_recebe_401_amigavel PASSED
tests/test_api.py::test_trace_id_do_cliente_e_propagado PASSED
tests/test_api.py::test_ativo_inexistente_404_em_portugues PASSED
tests/test_api.py::test_detalhe_e_telemetria PASSED
tests/test_api.py::test_validacao_vira_mensagem_legivel PASSED
tests/test_api.py::test_feedback_de_resumo PASSED
tests/test_api.py::test_erros_do_framework_saem_no_formato_padrao PASSED
tests/test_componentes.py::... PASSED                          (4 testes)
======================== 22 passed in 1.98s ========================
```

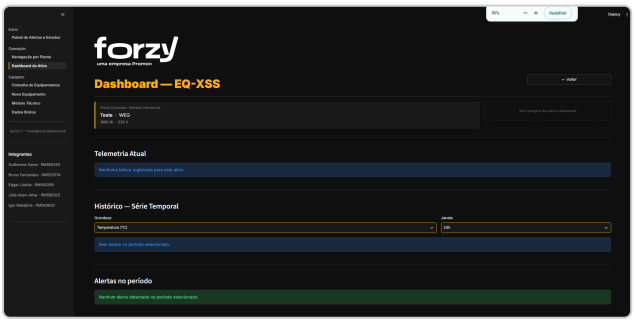
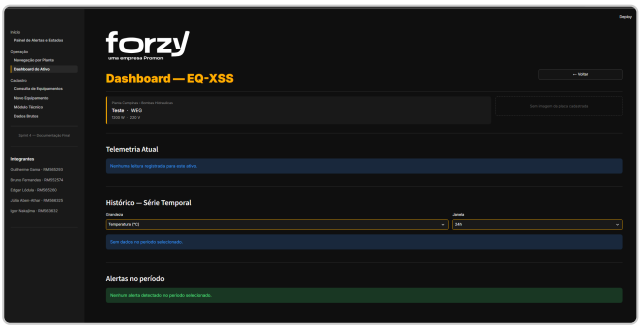
c) Reprodutibilidade (D3, D4)

```
# requirements.txt
-streamlit
-pandas
-numpy
-plotly
-pillow
-google-genai
-pyarrow
+streamlit==1.66.1
+pandas==3.1.0
+numpy==2.5.4
+plotly==7.1.0
+pillow==13.0.0
+google-genai==2.34.0
+pyarrow==26.0.1
```

Sem versão, cada `pip install` instalava a release mais recente — o app que funcionou na gravação do vídeo podia não funcionar na correção. As dependências de desenvolvimento ficaram separadas em `requirements-dev.txt` e as da API em `api/requirements.txt`, para que o front não instale FastAPI sem precisar.

Os quatro `.pyc` removidos (`app/__pycache__/componentes.cpython-314.pyc`, `dados.cpython-314.pyc`, ...) eram resto da estrutura da Sprint 1 e já estavam cobertos pelo `.gitignore` — só tinham entrado antes da regra existir.

d) Identificação da entrega

Antes	Depois
	

e) Linha do tempo do repositório

```
0c7ba79  2026-04-18  Sprint 1 - Interface Inicial
1219fbf  2026-04-18  feat: sprint 1 - interface de cadastro e consulta de equipamentos
b89f9f8  2026-05-24  sprint 2: dashboards operacionais, OCR Gemini, SQLite
4a1b2bc  2026-05-24  Organização do css do projeto
4df555c  2026-08-15  Sprint 3                                  ◄── ponto de partida
1ce16aa  2026-11-03  chore: remove bytecode compilado do versionamento
82f92e6  2026-11-03  fix: escapa texto dinamico nos componentes HTML
1c17b0b  2026-11-03  build: fixa versoes das dependencias
43695c3  2026-11-03  test: cobre detectores de anomalia e escape dos componentes
aa64f08  2026-11-03  feat(api): prototipo REST FastAPI sobre a camada de services
b111b0a  2026-11-03  chore: rotulo da sidebar para Sprint 4
e0727a6  2026-11-03  fix(api): erros do framework tambem no formato padrao
585134e  2026-11-03  fix(api): mensagem legivel para corpo que nao e JSON
```

---

3. Diferenciais e Resultados da Solução

3.1 Diferenciais técnicos e de experiência

Cores semânticas em toda a interface. Verde, amarelo e vermelho têm um significado só — dentro da baseline, desvio, ação imediata — e vêm de um único dicionário de tokens (`estilos.CORES`, `COR_BORDA_STATUS`). A mesma cor aparece no KPI, na borda do card, no badge, na faixa do gauge, na banda da série temporal e na coluna Status da consulta. O operador aprende o código uma vez.

Componentização. Toda peça visual repetida é uma função que devolve HTML a partir de dados: `html_card_alerta`, `html_card_recomendacao`, `html_kpi`, `html_painel_resumo`, `html_badge`, `html_card_equipamento`, `html_header_ativo`. As páginas só montam layout. Foi essa organização que permitiu corrigir a injeção de HTML (item 2.3a) em dois arquivos, sem tocar em nenhuma página.

Desacoplamento entre tela, análise e IA. A página nunca chama o detector nem a LLM. O fluxo é:

```
telemetria.py  (limite fixo) ─┐
                              ├─► resumos.py ─► eventos.py ─► painel_alertas.py
analitico.py   (detecção ML) ─┘     (NLP)        (SQLite)      (só lê eventos)
```

`pipeline_alertas.executar_ciclo()` grava eventos; o painel lê eventos. Trocar o previsor pela LSTM, o Gemini por outro modelo, ou a interface Streamlit por outro cliente não exige mexer nas outras camadas — a API da seção 5 é a prova: reaproveita `app/services/` sem reescrever regra.

Detecção que pega o que a regra fixa não pega. Três detectores complementares, cada um cobrindo um modo de falha:

Detector	Pega	Por que os outros não pegam
Resíduo de previsão	Spike, travamento	—
CUSUM do resíduo	Deriva lenta (rolamento degradando)	O erro instantâneo é minúsculo; só o acumulado mostra o viés
Variância da janela	Sensor congelado, link IO-Link caído	Sinal parado é *fácil* de prever: o resíduo cai em vez de subir

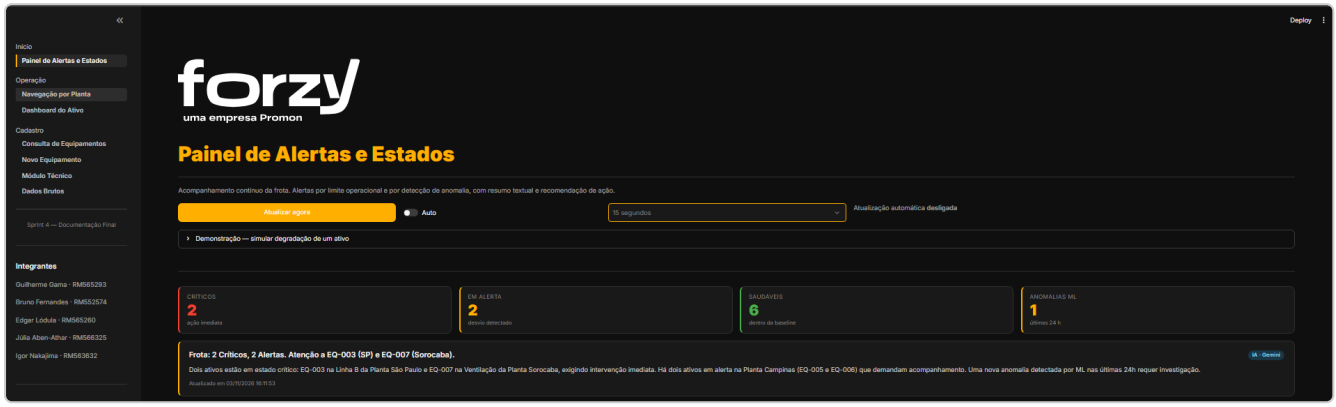
Os limiares saem da baseline de cada ativo (p99 do resíduo, múltiplo do CUSUM em operação normal), não de uma constante global.

IA que não quebra a tela. Os resumos usam Gemini 2.5 Flash com `response_schema` estrito e `temperature=0.2`. Sem chave, sem rede, cota estourada ou resposta inválida, o texto vem do gerador por template e o card mostra o selo `Resumo automático` em vez de `IA · Gemini`. Cache de 30 min por diagnóstico, deduplicação de eventos em 30 min e teto de 3 chamadas por ciclo mantêm o plano gratuito dentro da cota.

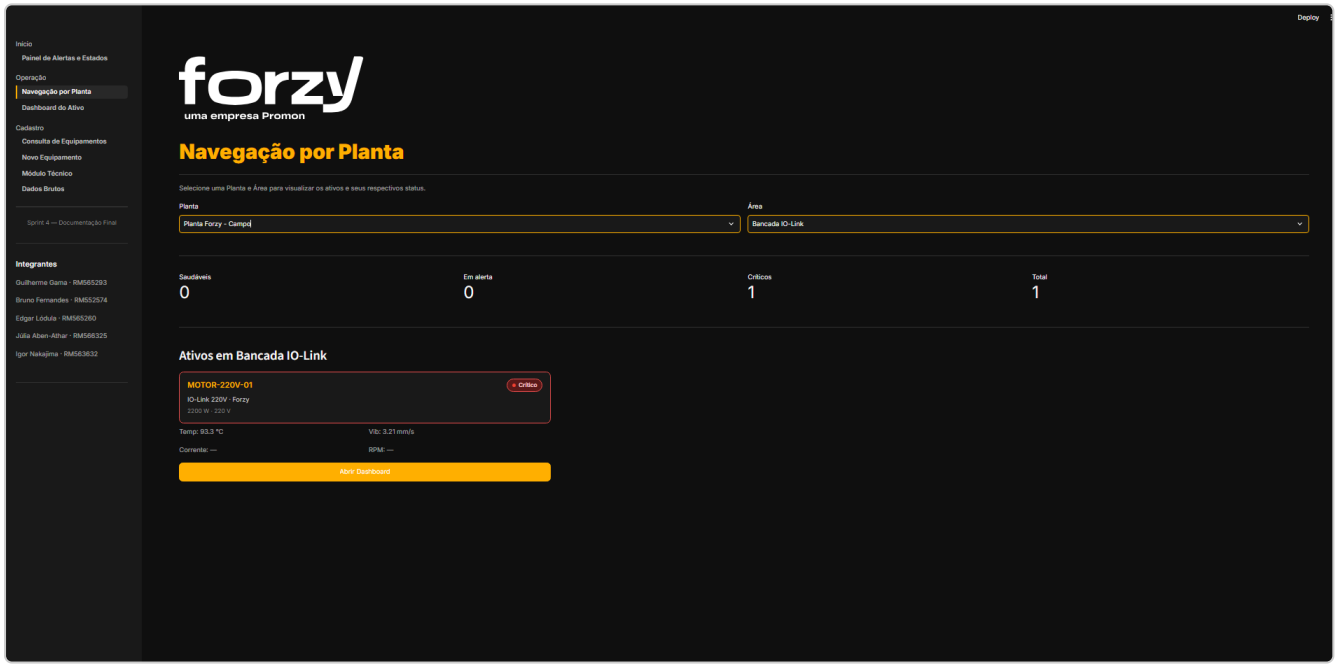
Rastreabilidade. Cada alerta é um registro na tabela `eventos` com origem (`limite` ou `ml`), score, limiar, detectores que dispararam, causa provável, texto gerado, origem do texto e se foi reconhecido. O histórico filtrável no fim do painel mostra isso; a API acrescenta `trace_id` por requisição e o feedback do operador por resumo.

3.2 Jornada do usuário — monitorar → receber alerta → agir

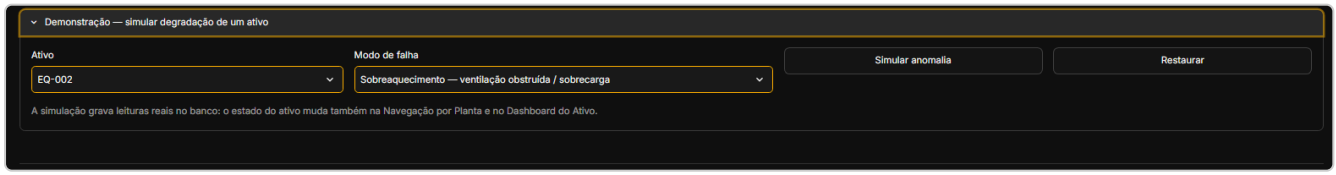
1. Monitorar. O painel abre direto no estado da frota: quantos ativos estão críticos, em alerta e saudáveis, quantas anomalias o modelo encontrou nas últimas 24 h, e um parágrafo escrito pela IA dizendo onde agir primeiro.

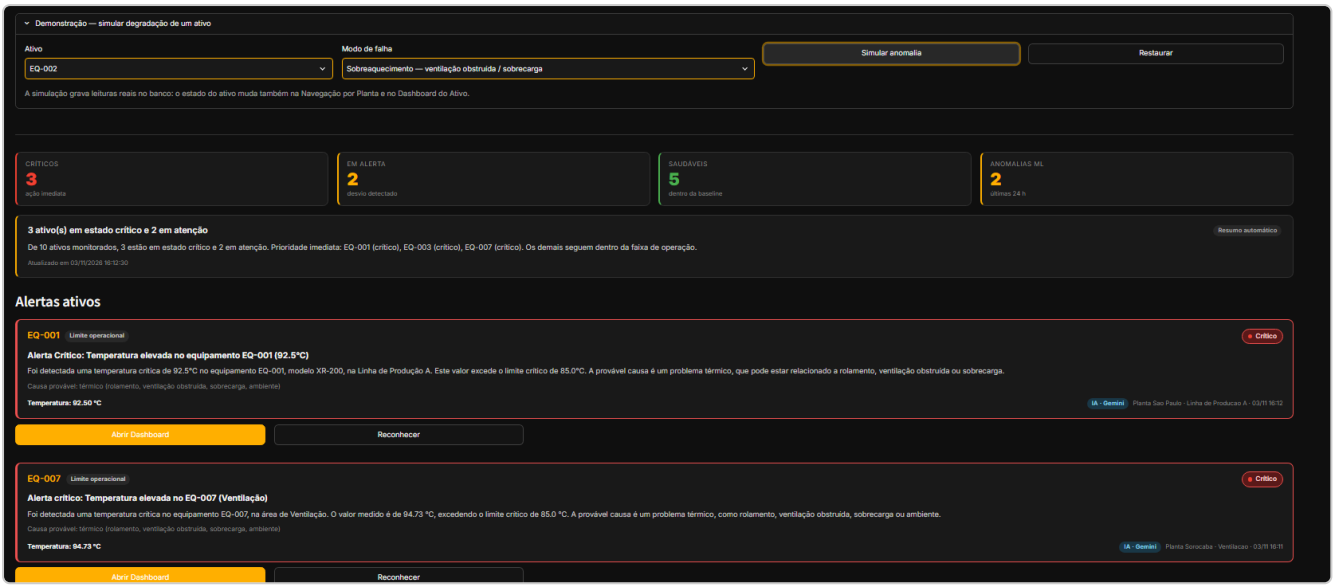


A Navegação por Planta dá a visão física: Planta → Área → cards dos ativos, já coloridos pelo status.

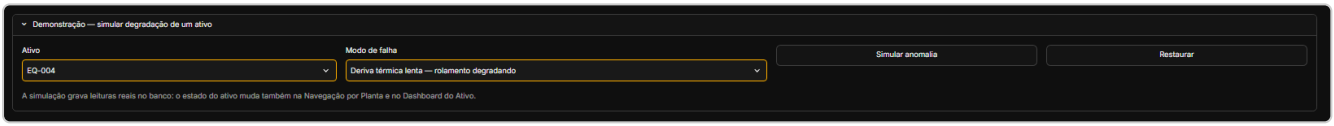


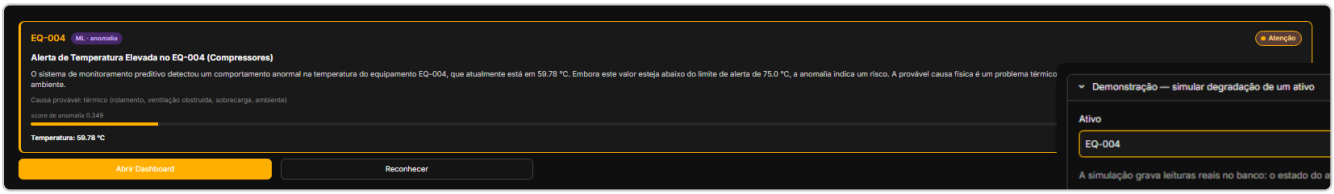
2. Receber o alerta. Quando um ativo sai da faixa, o card entra no topo do painel ordenado por severidade, com o título, a explicação em português, a causa provável e o valor medido. A demonstração injeta degradação real no banco pelo próprio painel.





O caso que mostra o valor da camada analítica: **deriva térmica lenta** no EQ-004. A temperatura sobe a 59,8 °C — abaixo do limite de alerta de 75 °C, então a regra fixa não dispara. O CUSUM dispara, e o card sai com o selo roxo `ML · anomalia` e a barra de score contra o limiar.

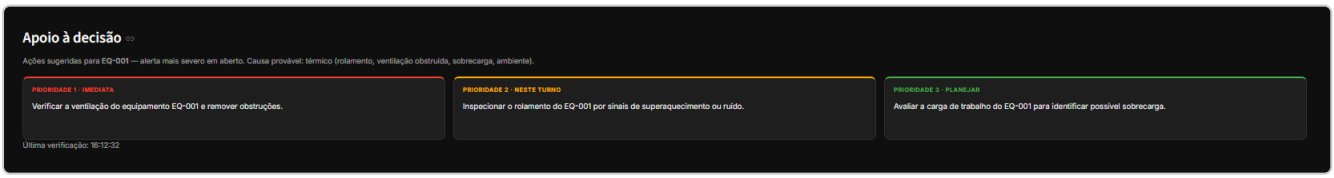




A mesma resposta, consultada pela API do protótipo, mostra qual detector disparou:

```
{"tag": "EQ-004", "alarme": true, "severidade": "warn",
 "feature_dominante": "temperatura",
 "detectores": {"residuo": false, "cusum": true, "variancia": false},
 "pista": "térmico (rolamento, ventilação obstruída, sobrecarga, ambiente)"}
```

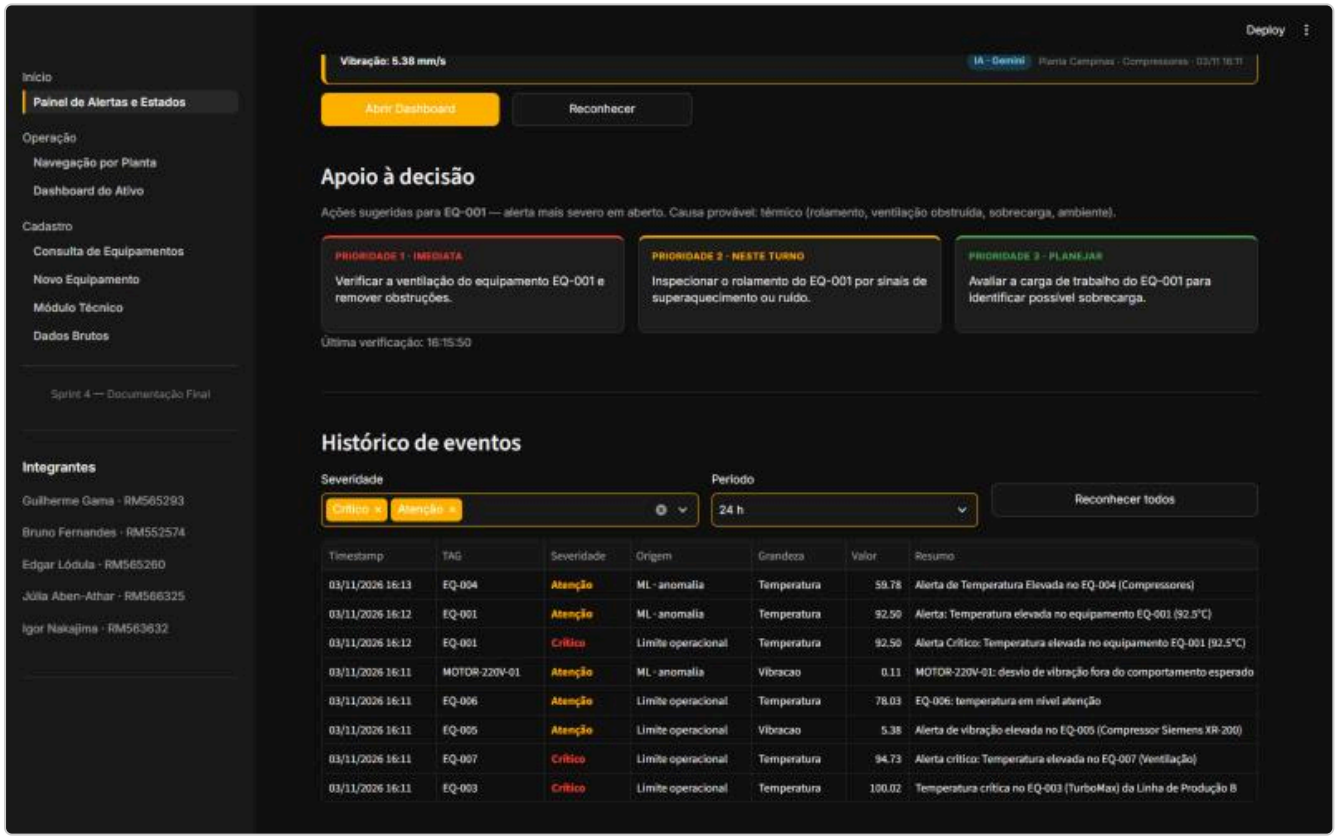
3. Agir. Abaixo dos alertas, três ações para o alerta mais severo, em ordem de execução e com a cor da urgência: imediata, neste turno, planejar.



"Abrir Dashboard" leva ao ativo, com os quatro gauges e o histórico para confirmar a tendência antes de mandar a equipe.

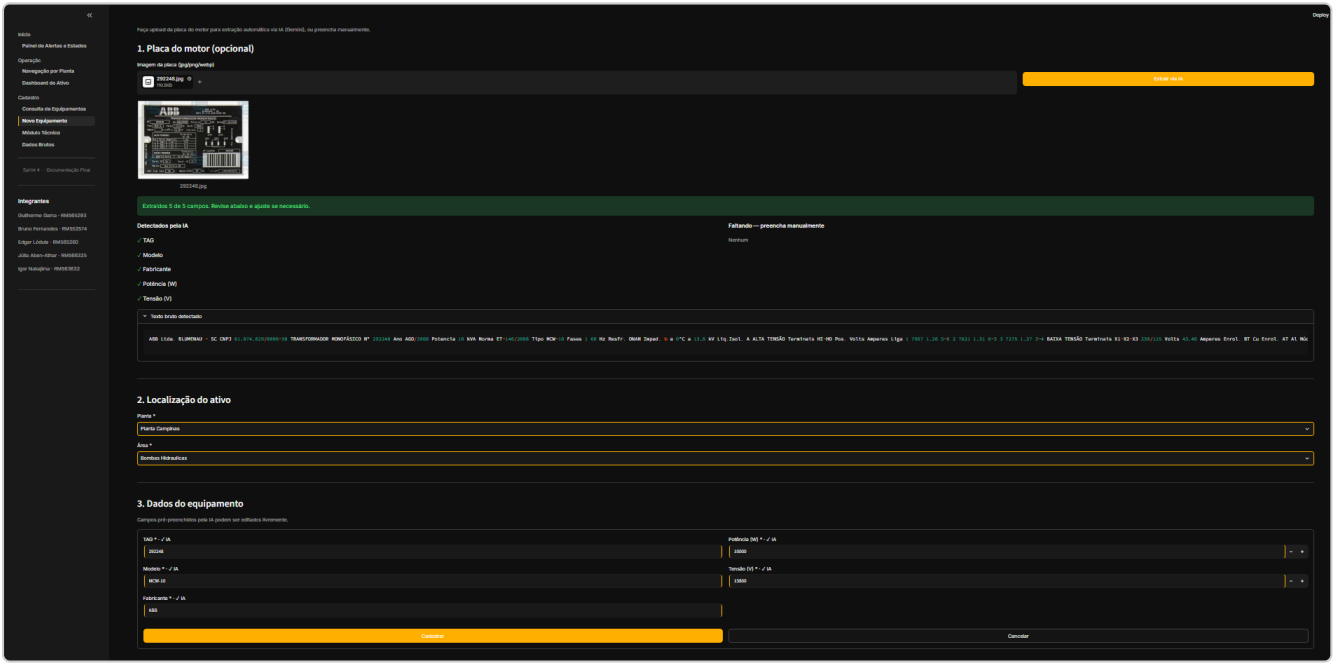


"Reconhecer" tira o alerta da lista ativa e ele permanece no histórico.



Cadastro com IA. Na entrada de um ativo novo, a foto da placa preenche os cinco campos. Cada campo mostra se veio da IA (✓) ou precisa ser preenchido (⚠), e todos continuam editáveis antes de salvar.


torzy
uma empresa Promon
Dashboard — EQ-004
Telemetria Atual
Temperatura
59.8 °C
Vibração
2.8 mm/s
Corrente
19.3 A
RPM
2831 RPM
Histórico — Série Temporal
Mínimo
45.87 °C
Máximo
59.14 °C
Média
47.74 °C
Desvio
1.17 °C
Alertas no período
Nenhum alerta detectado no período selecionado.


1. Placa do motor (opcional)
Extrair via IA
Extraídos 5 de 5 campos. Revise abaixo e ajuste se necessário.
Detectados pela IA
Faltando — preencha manualmente
2. Localização do ativo
3. Dados do equipamento
Cadastrar
Cancelar

3.3 Como a solução atende ao Challenge Forzy

Necessidade da Forzy	Resposta da solução
Saber o estado da frota sem abrir ativo por ativo	Painel inicial com KPIs, resumo executivo e alertas ordenados por severidade
Detectar degradação antes de virar falha	CUSUM pega deriva ainda dentro da faixa operacional (EQ-004, seção 3.2)
Entender o alerta sem ser especialista em dados	Resumo em português com causa provável e valor medido
Saber o que fazer	Três ações priorizadas por urgência
Cadastrar ativo sem digitação	OCR da placa com revisão humana
Usar dado real de campo	`MOTOR-220V-01` ingerido da camada Silver do Data Lake
Integrar com outros sistemas	Protótipo de API REST (seção 5)

4. Pendências, Justificativas e Melhorias Futuras

4.1 O que ficou pendente ou parcial

Item	Estado	Por que não foi feito
Previsor LSTM treinado	**Parcial.** O ponto de troca existe (`analitico._prever()`), mas o previsor em uso é uma média exponencial da janela	**Dependência de outra disciplina.** Os artefatos (`modelo_lstm.pt`, `scalers.pkl`, `metadados.json`) são produzidos no módulo de Modelagem e não foram publicados para o front. Os detectores já funcionam sobre o resíduo da média exponencial, como mostram os testes
Corrente e RPM do `MOTOR-220V-01`	Ausentes: gauges mostram "Sensor não instalado"	**Limitação física.** A bancada IO-Link tem só sensor de vibração e temperatura
RAG sobre o catálogo WEG	Não integrado. O corpus da Sprint 1 de PLN alimentou só os dados do EQ-009	**Escopo e prazo.** Exige base vetorial e recuperação, e a prioridade foi o ciclo de alerta
Autenticação de usuário na interface	Inexistente	**Escopo.** Login (OIDC) exige provedor de identidade configurado, fora do alcance da disciplina; a API da seção 5 introduz API Key como primeiro passo de controle de acesso
Persistência multiusuário	SQLite local, um processo	**Decisão de escopo.** Adequado para demonstração; produção exige banco servidor (seção 5)
Cota do Gemini	O plano gratuito limita requisições diárias	**Limitação externa.** Mitigada por cache, deduplicação e fallback, sem quebrar a tela
Responsividade mobile	Layout pensado para desktop	**Limitação técnica.** `st.columns` não reflui bem em tela estreita; o operador de campo usa tablet ou desktop
Testes das páginas Streamlit	Cobertos só os serviços, componentes e API	**Complexidade.** `streamlit.testing` existe, mas não houve prazo para cobrir as sete telas

4.2 Melhorias priorizadas

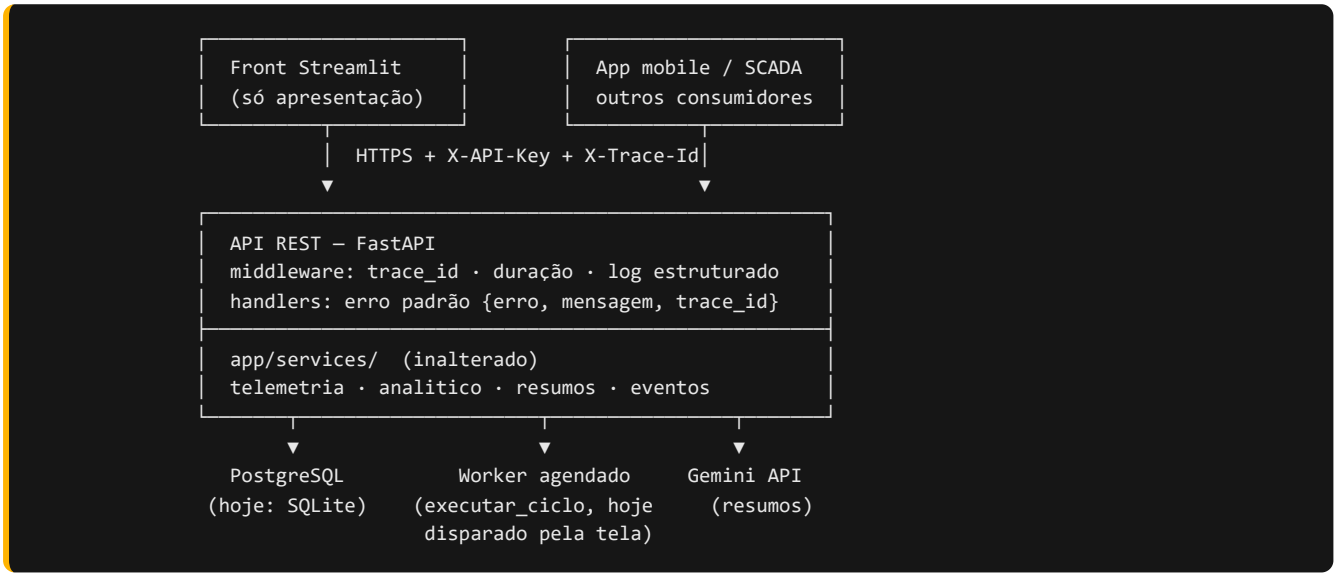
Prioridade	Melhoria	Esforço	Viabilidade
P1	Plugar a LSTM em `_prever()` assim que os artefatos forem publicados	Baixo, uma função	Alta: o contrato `Diagnostico` não muda
P1	Migrar o front para consumir a API em vez de importar `app/services/`	Médio	Alta: os endpoints já existem
P2	Botões 👍 / 👎 nos cards de alerta gravando em `POST /eventos/{id}/feedback`	Baixo	Alta: backend pronto
P2	Trocar SQLite por PostgreSQL e o timer por um worker agendado	Médio	Alta
P3	RAG sobre manuais e catálogos para enriquecer as recomendações	Alto	Média: depende de curadoria do corpus
P3	Interface mobile dedicada para o técnico em campo	Alto	Média

5. Ir além — Proposta de arquitetura de produção

5.1 Problema

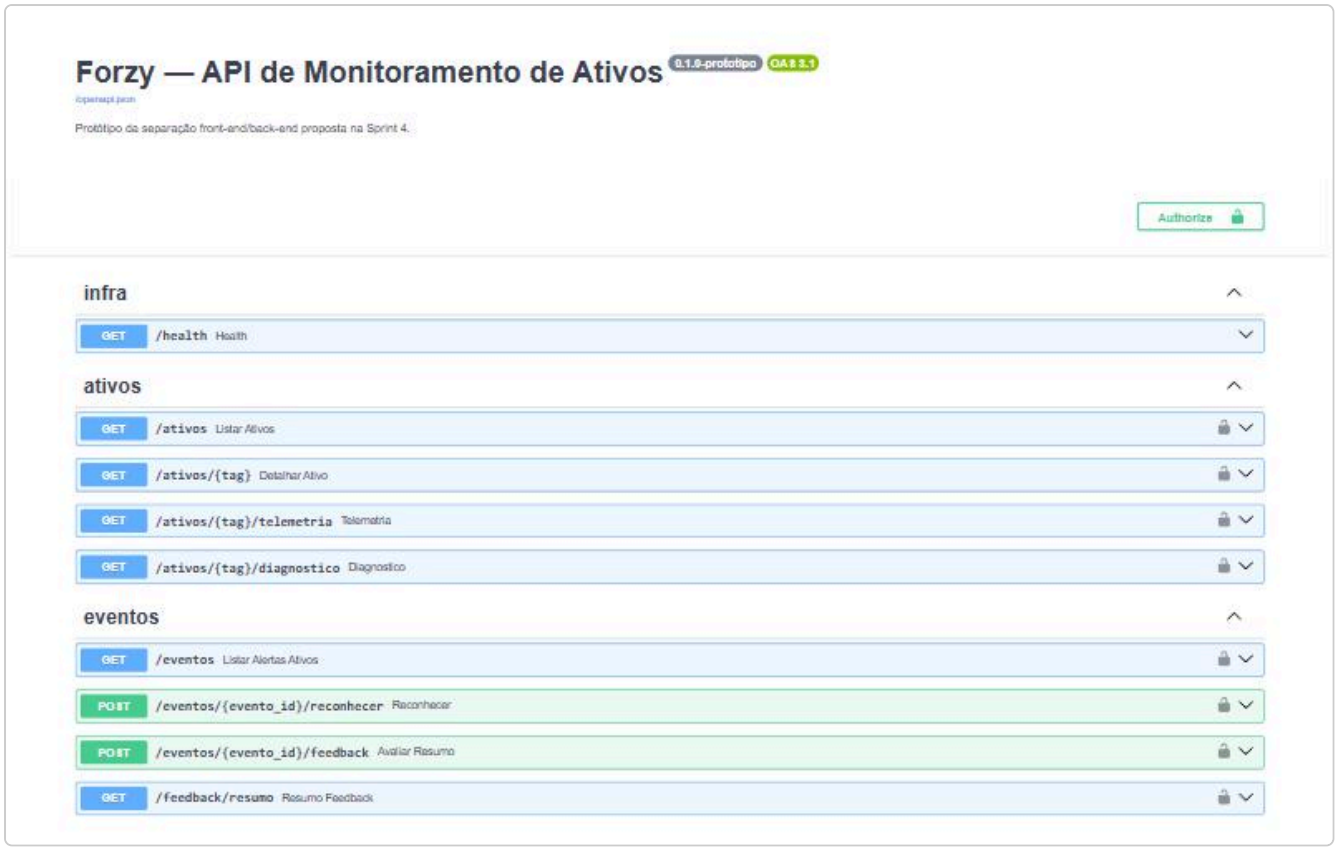
Hoje a interface Streamlit **é** o backend: a página importa `app/services/` e acessa o SQLite no mesmo processo. Consequências: só um tipo de cliente; cada aba aberta roda o pipeline de alertas; não há autenticação; um erro técnico aparece cru para o operador; e não há como relacionar a queixa de um usuário com o que aconteceu no servidor.

5.2 Arquitetura proposta



5.3 Protótipo implementado

Pasta `api/`, commit `aa64f08`. Roda com `uvicorn api.main:app --port 8000`; documentação interativa em `/docs`.



Método	Rota	Função	Auth
GET	`/health`	Healthcheck do balanceador	pública
GET	`/ativos`	Lista de ativos com planta e área	API Key
GET	`/ativos/{tag}`	Ficha, última leitura e status por grandeza	API Key
GET	`/ativos/{tag}/telemetria?janela=1h|3h|24h|7d`	Série histórica	API Key
GET	`/ativos/{tag}/diagnostico`	Os 3 detectores sobre o histórico	API Key
GET	`/eventos?horas=24`	Alertas ativos, mais severo primeiro	API Key
POST	`/eventos/{id}/reconhecer`	Reconhece um alerta	API Key
POST	`/eventos/{id}/feedback`	Feedback do operador sobre o resumo da IA	API Key
GET	`/feedback/resumo`	Taxa de aprovação por origem do texto (Gemini × template)	API Key

Autenticação por API Key. Header `X-API-Key`, comparado com a variável de ambiente `FORZY_API_KEY`. Se a variável não estiver configurada a API responde 503 em tudo, porque subir aberta por esquecimento é pior do que não subir.

Observabilidade. O middleware aceita o `X-Trace-Id` do cliente, ou gera um, e devolve no header da resposta, no corpo de erro e em cada linha de log, junto com `X-Duracao-Ms`. Um print de erro enviado pelo operador leva direto à linha do log do servidor.

Erros amigáveis. Todo erro sai no mesmo formato, em português, sem stack trace:

```
$ curl -i http://localhost:8000/ativos           # sem X-API-Key
HTTP/1.1 401 Unauthorized
x-trace-id: 66060ca09d7f4fed
{"erro":"nao_autorizado","mensagem":"Chave de API ausente ou inválida (header X-API-
Key).","trace_id":"66060ca09d7f4fed"}

$ curl -H "X-API-Key: ***" http://localhost:8000/ativos/NAO-EXISTE
{"erro":"nao_encontrado","mensagem":"Ativo NAO-EXISTE não encontrado.","trace_id":"4c6e279e6d6247d8"}

$ curl -X POST ... -d "{nao e json" http://localhost:8000/eventos/1/feedback
{"erro":"dados_invalidos","mensagem":"Corpo da requisição não é um JSON válido.","trace_id":"ac3c85b219e34f94"}
```

Ao capturar estas evidências, o grupo encontrou dois casos em que o erro ainda saía no formato cru do framework (`{"detail": "There was an error parsing the body"}`). O handler estava registrado na `HTTPException` do FastAPI, mas o Starlette levanta a classe-mãe. Os commits `e0727a6` e `585134e` corrigem isso, com teste.

Trace propagado pelo cliente:

```
$ curl -i -H "X-API-Key: ***" -H "X-Trace-Id: demo-sprint4" http://localhost:8000/ativos/EQ-004/diagnostico
HTTP/1.1 200 OK
x-trace-id: demo-sprint4
x-duracao-ms: 12
{"tag":"EQ-004","score":0.3539,"threshold":1.7317,"alarme":true,"severidade":"warn",
 "detectores":{"residuo":false,"cusum":true,"variancia":false}, ...}
```

Feedback do usuário em respostas de IA. Cada avaliação guarda o evento, útil sim/não, comentário e o `trace_id`. Agregado por origem do texto, permite medir se o Gemini de fato escreve melhor que o template — hoje isso é suposição.

```
$ curl -X POST -H "X-API-Key: ***" -H "Content-Type: application/json" \
       -d '{"util": true, "comentario": "Recomendação correta"}' http://localhost:8000/eventos/6/feedback
{"evento_id":6,"registrado":true}

$ curl -H "X-API-Key: ***" http://localhost:8000/feedback/resumo
[{"origem_resumo":"gemini","avaliacoes":1,"uteis":1,"taxa_aprovacao":1.0}]
```

5.4 Plano de migração

Fase	Entrega	Risco que remove
0 — feito	API lendo a mesma camada de serviços, com auth, trace e erros padronizados	Prova que a separação não exige reescrever regra
1	Front passa a chamar a API via `httpx`; `pipeline_alertas.executar_ciclo()` sai da página para um worker com agendamento	Cada aba aberta deixa de rodar o pipeline
2	Remover `import streamlit` de `resumos.py`, `pipeline_alertas.py` e `gemini_client.py` (hoje usam `st.cache_data` e `st.secrets`), trocando por cache próprio e variável de ambiente	Serviços ficam independentes de framework de UI
3	SQLite → PostgreSQL; API Key por cliente com rotação	Concorrência e revogação de acesso
4	Botões de feedback nos cards; painel de qualidade da IA	Decidir com dado se o custo do Gemini se paga

6. Conclusão

Ao longo de quatro sprints a solução saiu de um formulário de cadastro e chegou a um painel que diz ao operador qual motor está degradando, explica em português o que aconteceu e propõe a ação, inclusive para desvios que ainda estão dentro da faixa operacional e que uma regra de limite não veria.

A Sprint 4 tratou o que a entrega da Sprint 3 deixava frágil, sem acrescentar funcionalidade:

- **Escape de HTML.** Texto vindo de OCR e de LLM não vira mais marcação na tela.
- **Testes.** Os detectores, que antes eram validados no olho durante a demo, agora são verificados por 22 testes.
- **Dependências.** As versões estão fixas e o projeto instala igual em qualquer máquina.
- **Arquitetura.** A separação entre front e back foi demonstrada com um protótipo de API que reaproveita a camada de serviços sem reescrever regra.
- **Erros da API.** Dois erros do próprio protótipo apareceram durante a captura de evidências e foram corrigidos.

A pendência principal é a LSTM, que depende da disciplina de Modelagem. O código está preparado para recebê-la em uma única função. Os próximos passos mais baratos e de maior efeito são o front consumir a API e os botões de feedback nos cards.

Anexo — Como executar

```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements-dev.txt

streamlit run main.py                       # front: http://localhost:8501
$env:FORZY_API_KEY = "<chave>"               # PowerShell
uvicorn api.main:app --port 8000            # API:   http://localhost:8000/docs
pytest                                      # 22 testes
```

A chave do Gemini (`GEMINI_API_KEY`) é opcional. Sem ela, os resumos são gerados por template. Na primeira execução, `data/forzy.db` é criado com 7 dias de histórico e o motor real é ingerido do Parquet.